

Trabajo Práctico 3

Dos sesgos que tiran para lados distintos

Luca Armelini

Economía Aplicada

Universidad de San Andrés

1 de septiembre de 2026

1 Derivaciones

(a) La omitida: derivación de δ

Observamos X_1^* y X_2 queda omitida. Regresamos Y sobre X_1^* . El estimador MCO es

$$\hat{\beta}_1 = \left(\frac{1}{n} X_1^{*'} X_1^* \right)^{-1} \left(\frac{1}{n} X_1^{*'} Y \right).$$

Dado $\nu = 0$, reemplazamos por el DGP verdadero:

$$\hat{\beta}_1 = \left(\frac{1}{n} X_1^{*'} X_1^* \right)^{-1} \frac{1}{n} X_1^{*'} (X_1^* \beta_1 + X_2 \beta_2 + e).$$

Distribuyendo y notando que $\left(\frac{1}{n} X_1^{*'} X_1^* \right)^{-1} \frac{1}{n} X_1^{*'} X_1^* = I$:

$$\hat{\beta}_1 = \beta_1 + \left(\frac{1}{n} X_1^{*'} X_1^* \right)^{-1} \frac{1}{n} X_1^{*'} X_2 \beta_2 + \left(\frac{1}{n} X_1^{*'} X_1^* \right)^{-1} \frac{1}{n} X_1^{*'} e.$$

Tomamos plim en ambos lados. El primer término es β_1 , por ser una constante. El tercero se anula debido a que $E(X_1^{*'} e) = 0$ y $[E(X_1^{*'} X_1^*)]^{-1}$ es finita (invertible por enunciado), entonces el producto es finito $\times 0$:

$$\text{plim } \hat{\beta}_1 = \beta_1 + \text{plim} \left[\left(\frac{1}{n} X_1^{*'} X_1^* \right)^{-1} \frac{1}{n} X_1^{*'} X_2 \right] \beta_2.$$

En el término restante, el plim de un producto es el producto de los plims, y el plim de la inversa es la inversa del plim:

$$\text{plim } \hat{\beta}_1 = \beta_1 + [\text{plim } \frac{1}{n} X_1^{*'} X_1^*]^{-1} \text{plim } \frac{1}{n} X_1^{*'} X_2 \beta_2.$$

Por definición $\text{plim } \frac{1}{n} X_1^{*'} X_1^* = E(X_1^{*'} X_1^*)$ y $\text{plim } \frac{1}{n} X_1^{*'} X_2 = E(X_1^{*'} X_2)$, de modo que:

$$\boxed{\text{plim } \hat{\beta}_1 = \beta_1 + \delta \beta_2, \quad \delta = [E(X_1^{*'} X_1^*)]^{-1} E(X_1^{*'} X_2).}$$

Nótese que δ es el coeficiente de MCO de regresar la omitida X_2 sobre la incluida X_1^* .

(b) El error de medición

Ahora asumimos $\beta_2 = 0$, pero regresando Y sobre X_1 , la variable reportada y contaminada, y no sobre X_1^* . Comenzamos con la expresión inicial del estimador:

$$\hat{\beta}_1 = \left(\frac{1}{n} X_1' X_1 \right)^{-1} \left(\frac{1}{n} X_1' Y \right).$$

Reemplazando el nuevo DGP $Y = X_1^* \beta_1 + e$ y $X_1 = X_1^* + \nu$ en todos los factores:

$$\hat{\beta}_1 = \left[\frac{1}{n} (X_1^* + \nu)' (X_1^* + \nu) \right]^{-1} \left[\frac{1}{n} (X_1^* + \nu)' (X_1^* \beta_1 + e) \right].$$

Multiplicando los términos en los corchetes:

$$\hat{\beta}_1 = \left[\frac{1}{n} X_1^{*'} X_1^* + \frac{1}{n} X_1^{*'} \nu + \frac{1}{n} \nu' X_1^* + \frac{1}{n} \nu' \nu \right]^{-1} \left[\frac{1}{n} X_1^{*'} X_1^* \beta_1 + \frac{1}{n} X_1^{*'} e + \frac{1}{n} \nu' X_1^* \beta_1 + \frac{1}{n} \nu' e \right].$$

Tomamos plim. Por los supuestos $E(X_1^{*'} \nu) = 0$, $E(X_1^{*'} e) = 0$ y $E(\nu' e) = 0$, todos los términos cruzados se anulan:

$$\text{plim } \hat{\beta}_1 = [E(X_1^{*'} X_1^*) + E(\nu' \nu)]^{-1} E(X_1^{*'} X_1^*) \beta_1.$$

Definiendo Λ como el factor que multiplica a β_1 :

$$\text{plim } \hat{\beta}_1 = \Lambda \beta_1, \quad \Lambda = [E(X_1^{*'} X_1^*) + E(v'v)]^{-1} E(X_1^{*'} X_1^*).$$

Tomamos la definición de λ de la consigna:

$$\lambda = \frac{V(x_1^*)}{V(x_1^*) + V(v)}.$$

La expresión anterior denota qué parte de la variabilidad total de X_1 es explicada por la variabilidad de la señal. λ está necesariamente en el intervalo $(0, 1]$, ya que es un cociente de varianzas (siempre positivo) cuyo denominador es el numerador más un término de error $V(v) \geq 0$, por lo que el cociente es menor o igual a 1. El único caso en que $\lambda = 1$ es cuando $V(v) = 0$, es decir, cuando toda la varianza de X_1 es señal (no hay error de medición).

(c) Las dos fuerzas juntas

Ahora X_2 está omitida y X_1 mal medida a la vez. El DGP completo es $Y = X_1^* \beta_1 + X_2 \beta_2 + e$ y regresamos Y sobre $X_1 = X_1^* + v$:

$$\hat{\beta}_1 = \left(\frac{1}{n} X_1' X_1 \right)^{-1} \left(\frac{1}{n} X_1' Y \right).$$

El denominador es el mismo que en (b), ya que no depende de Y :

$$\text{plim } \frac{1}{n} X_1' X_1 = E(X_1^{*'} X_1^*) + E(v'v).$$

En el numerador reemplazamos Y y $X_1 = X_1^* + v$, y expandimos:

$$\frac{1}{n} X_1' Y = \frac{1}{n} (X_1^* + v)' (X_1^* \beta_1 + X_2 \beta_2 + e).$$

Al tomar plim, por los supuestos $E(X_1^{*'} e) = E(v' X_1^*) = E(X_2' v) = E(v' e) = 0$, todos los términos con e o con v cruzado se anulan, y sobreviven la señal y el término de la omitida:

$$\text{plim } \frac{1}{n} X_1' Y = E(X_1^{*'} X_1^*) \beta_1 + E(X_1^{*'} X_2) \beta_2.$$

Juntando numerador y denominador:

$$\text{plim } \hat{\beta}_1 = [E(X_1^{*'} X_1^*) + E(v'v)]^{-1} [E(X_1^{*'} X_1^*) \beta_1 + E(X_1^{*'} X_2) \beta_2].$$

Recordemos que en (a) definimos $\delta = [E(X_1^{*'} X_1^*)]^{-1} E(X_1^{*'} X_2)$, lo que se puede reescribir como $E(X_1^{*'} X_2) = E(X_1^{*'} X_1^*) \delta$. Sustituyendo esto en el segundo corchete:

$$\text{plim } \hat{\beta}_1 = [E(X_1^{*'} X_1^*) + E(v'v)]^{-1} [E(X_1^{*'} X_1^*) \beta_1 + E(X_1^{*'} X_1^*) \delta \beta_2].$$

Factorizando $E(X_1^{*'} X_1^*)$ en el segundo corchete:

$$\text{plim } \hat{\beta}_1 = [E(X_1^{*'} X_1^*) + E(v'v)]^{-1} E(X_1^{*'} X_1^*) (\beta_1 + \delta \beta_2).$$

El factor que multiplica a $(\beta_1 + \delta \beta_2)$ es el Λ de (b). Por tanto:

$$\text{plim } \hat{\beta}_1 = \Lambda (\beta_1 + \delta\beta_2).$$

Con $k = 1$, usando intercepto se tiene $\Lambda \rightarrow \lambda$, con lo que:

$$\text{plim } \hat{\beta}_1 = \lambda (\beta_1 + \delta\beta_2).$$

Buscamos la condición bajo la cual $\text{plim } \hat{\beta}_1 = \beta_1$ sin que ninguno de los dos sesgos sea cero ($\lambda \neq 1$ y $\delta\beta_2 \neq 0$). Igualando y despejando:

$$\lambda (\beta_1 + \delta\beta_2) = \beta_1 \implies \lambda\delta\beta_2 = \beta_1(1 - \lambda) \implies \delta\beta_2 = \frac{\beta_1(1 - \lambda)}{\lambda}.$$

(d) Controlar empeora

Ahora X_2 se observa y la incluimos como control. Consecuentemente, regresamos Y sobre $[X_1 \ X_2]$. Por Frisch–Waugh–Lovell, el coeficiente de X_1 es el de regresar Y sobre X_1 , ambos previamente limpiados respecto de X_2 mediante $M_2 = I - X_2(X_2'X_2)^{-1}X_2'$:

$$\hat{\beta}_1 = \left(\frac{1}{n}X_1'M_2X_1\right)^{-1} \left(\frac{1}{n}X_1'M_2Y\right).$$

En el denominador (término izquierdo), reemplazamos $X_1 = X_1^* + \nu$ en los dos lugares donde aparece X_1 :

$$\frac{1}{n}(X_1^* + \nu)'M_2(X_1^* + \nu).$$

Expandimos el producto, de la forma $(a + b)'M_2(a + b)$, que da cuatro términos:

$$\frac{1}{n} \left[X_1^{*'}M_2X_1^* + X_1^{*'}M_2\nu + \nu'M_2X_1^* + \nu'M_2\nu \right].$$

Por supuestos, sabemos que ν no correlaciona ni con X_1^* , ni con X_2 . Consecuentemente, los términos cruzados del medio se van a 0:

$$\frac{1}{n} \left[X_1^{*'}M_2X_1^* + \nu'M_2\nu \right].$$

Tomando plim, cada promedio converge a su valor poblacional. El término de la señal tiende a $E(X_1^{*'}M_2X_1^*)$; el del ruido, a $E(\nu'M_2\nu) = E(\nu'\nu)$, ya que la proyección de ν sobre X_2 es nula en $\text{plim } (E(X_2'\nu) = 0)$ y M_2 lo deja intacto. Dicho lo anterior:

$$\text{plim } \frac{1}{n}X_1'M_2X_1 = E(X_1^{*'}M_2X_1^*) + E(\nu'\nu).$$

En el numerador (término derecho), reemplazamos X_1 igual que en el término anterior, e Y por el respectivo DGP:

$$\frac{1}{n}X_1'M_2Y = \frac{1}{n}(X_1^* + \nu)'M_2(X_1^*\beta_1 + X_2\beta_2 + e).$$

Distribuyendo M_2 sobre los tres términos del DGP:

$$\frac{1}{n} X_1' M_2 Y = \frac{1}{n} (X_1^* + \nu)' [M_2 X_1^* \beta_1 + M_2 X_2 \beta_2 + M_2 e].$$

El término de la omitida se anula al añadir el control, pues $M_2 X_2 = 0$. Expandiendo lo que queda:

$$\frac{1}{n} X_1' M_2 Y = \frac{1}{n} X_1^{*'} M_2 X_1^* \beta_1 + \frac{1}{n} X_1^{*'} M_2 e + \frac{1}{n} \nu' M_2 X_1^* \beta_1 + \frac{1}{n} \nu' M_2 e.$$

Tomando plim, los tres últimos términos se anulan por los supuestos $E(X_1^{*'} e) = 0$, $E(X_2' e) = 0$, $E(\nu' X_1^*) = 0$, $E(X_2' \nu) = 0$ y $E(\nu' e) = 0$. Sobrevive solo la señal residualizada:

$$\text{plim } \frac{1}{n} X_1' M_2 Y = E(X_1^{*'} M_2 X_1^*) \beta_1.$$

Juntando numerador y denominador, se obtiene:

$$\text{plim } \hat{\beta}_1 = [E(X_1^{*'} M_2 X_1^*) + E(\nu' \nu)]^{-1} E(X_1^{*'} M_2 X_1^*) \beta_1.$$

Definiendo Λ_2 como el factor que multiplica a β_1 :

$$\text{plim } \hat{\beta}_1 = \Lambda_2 \beta_1, \quad \Lambda_2 = [E(X_1^{*'} M_2 X_1^*) + E(\nu' \nu)]^{-1} E(X_1^{*'} M_2 X_1^*).$$

Ahora, asumiendo $k = 1$, con intercepto $E(\nu' \nu) = V(\nu)$ y $E(X_1^{*'} M_2 X_1^*) = V(\tilde{x}_1^*)$, la varianza del residuo de regresar x_1^* sobre x_2 :

$$V(\tilde{x}_1^*) = V(x_1^*) - \frac{\text{Cov}(x_1^*, x_2)^2}{V(x_2)}.$$

El factor de atenuación queda:

$$\lambda_2 = \frac{V(\tilde{x}_1^*)}{V(\tilde{x}_1^*) + V(\nu)}.$$

Como $\text{Cov}(x_1^*, x_2) \neq 0$ y $V(x_2) > 0$, se tiene $V(\tilde{x}_1^*) < V(x_1^*)$. Dado que $\frac{a}{a+V(\nu)}$ es creciente en a , reducir el numerador manteniendo $V(\nu) > 0$ reduce el cociente:

$$\lambda_2 = \frac{V(\tilde{x}_1^*)}{V(\tilde{x}_1^*) + V(\nu)} < \frac{V(x_1^*)}{V(x_1^*) + V(\nu)} = \lambda.$$

Controlar por x_2 residualiza x_1^* y le quita la parte de señal que compartía con x_2 , pero deja intacto el ruido ν , que no correlaciona con x_2 . Bajamos la señal pero mantenemos la misma cantidad de ruido, de modo que la atenuación por omisión empeora.

Como $\text{plim } \hat{\beta}_1 = \lambda_2 \beta_1$, solo se recupera β_1 si $\lambda_2 = 1$, es decir $V(\nu) = 0$. Al eliminar la omitida se pierde la cancelación de (c), y sin un segundo sesgo que compense la única forma de acertar es que no haya error de medición.

2 Simulación

(a) Verificación de las derivaciones

Generamos $R = 500$ réplicas de tamaño $n = 2000$ y estimamos en cada una las dos regresiones: y sobre x_1 (sin control) y y sobre x_1 y x_2 (con control). Los valores teóricos surgen de los parámetros del DGP: con $\beta_1 = -0,10$, $\beta_2 = -0,20$, $\delta = 0,2$, $\lambda = 0,5$ y $\lambda_2 = 4/9$, resultan $\lambda(\beta_1 + \delta\beta_2) = -0,07$ para la regresión sin control y $\lambda_2\beta_1 = -0,0444$ para la regresión con control.

Cuadro 1: Verificación Monte Carlo, $n = 2000$, $R = 500$.

	Fórmula	Teórico	Prom. simulado	MCse
$\hat{\beta}_1$ sin control	$\lambda(\beta_1 + \delta\beta_2)$	-0.0700	-0.0700	0.00033
$\hat{\beta}_1$ con control	$\lambda_2\beta_1$	-0.0444	-0.0445	0.00035

El promedio simulado coincide con el valor teórico en ambas filas (la diferencia es menor a dos MCse), lo que confirma las derivaciones de la Parte 1. Ninguna de las dos regresiones recupera el efecto verdadero $\beta_1 = -0,10$: sin control el sesgo por omitida y la atenuación se combinan en $-0,07$, y al agregar el control el estimador se aleja aún más, hasta $-0,0444$, ilustrando que controlar empeora.




Figura 1: Distribución de $\hat{\beta}_1$ sin control para $n = 500$ y $n = 2000$ ($R = 500$ réplicas). Líneas verticales: $\beta_1 = -0,10$ (verdadero, punteada) y el plim $-0,07$ (rojo).

Al aumentar n de 500 a 2000, la campana se angosta: la varianza del estimador cae y las réplicas se concentran más. Lo que n no modifica es el centro de la distribución, que permanece en el plim $-0,07$ y no en $\beta_1 = -0,10$. Al agregar más datos se aporta precisión en torno al valor sesgado, pero no corrigen el sesgo.

(b) Barrido de λ

Repetimos la regresión sin control (y sobre x_1) con $n = 2000$, variando la confiabilidad sobre el conjunto, de muy baja a muy alta:

$$\lambda \in \{0,15; 0,3; 0,5; 0,7; 0,9; 1\}.$$

Para cada valor mantenemos la varianza de la señal $V(x_1^*) = 5$ fija y ajustamos la varianza del error como

$$V(v) = V(x_1^*) \frac{1 - \lambda}{\lambda},$$

de modo que solo cambia la proporción de ruido en la variable observada. De la condición de 1(c), la curva cruza β_1 cuando $\lambda(\beta_1 + \delta\beta_2) = \beta_1$, es decir en

$$\lambda^* = \frac{\beta_1}{\beta_1 + \delta\beta_2} = \frac{-0,10}{-0,14} = \frac{5}{7} \approx 0,714.$$




Figura 2: Promedio de $\hat{\beta}_1$ sin control frente a la confiabilidad λ ($n = 2000$, $R = 500$). Línea horizontal punteada: $\beta_1 = -0,10$. Línea vertical roja: $\lambda^* \approx 0,714$, donde la curva cruza el valor verdadero.

En λ^* MCO recupera β_1 porque ambos sesgos se cancelan exactamente. La atenuación compensa justo al sesgo por omitida. Para cualquier otro λ una fuerza domina a la otra y $\hat{\beta}_1 \neq \beta_1$; nótese que en $\lambda = 1$ (sin error de medición) el estimador vale $\beta_1 + \delta\beta_2 = -0,14$, y es al bajar λ que se acerca a $-0,10$.

(c) Corrección por confiabilidad

Tomamos las $R = 500$ estimaciones sin control de (a), dividimos cada una por λ y promediamos. Como el sin control converge a $\lambda(\beta_1 + \delta\beta_2)$, al dividir por λ el estimador corregido converge a

$$\frac{\lambda(\beta_1 + \delta\beta_2)}{\lambda} = \beta_1 + \delta\beta_2 = -0,10 + (-0,04) = -0,14.$$

Corrigiendo por confiabilidad deshacemos la atenuación, pero se mantienen el sesgo por omisión. El estimador corregido converge a $-0,14$, no al valor verdadero $\beta_1 = -0,10$. De hecho, corregir aleja el resultado de la verdad respecto del sin corregir ($-0,07$). Al remover la atenuación se destapa la omitida, que antes quedaba parcialmente compensada por aquella.

3 El control tentador

(a) Sin control

Regresamos Y sobre D . Con una sola variable centrada, el estimador MCO es la covarianza sobre la varianza, cuyo plim es

$$\text{plim } \hat{\beta}_D = \frac{\text{Cov}(D, Y)}{V(D)} = \frac{E(D'Y)}{E(D'D)}.$$

Sustituimos $C = \gamma D + \pi A + u$ en el DGP de $Y = \beta D + \rho C + \theta A + e$ para obtener la forma reducida en función de D :

$$Y = \beta D + \rho(\gamma D + \pi A + u) + \theta A + e = (\beta + \rho\gamma)D + (\rho\pi + \theta)A + \rho u + e.$$

Reemplazamos la forma reducida de Y en el numerador y distribuimos $\frac{1}{n}D'$:

$$\frac{1}{n}D'Y = (\beta + \rho\gamma) \frac{1}{n}D'D + (\rho\pi + \theta) \frac{1}{n}D'A + \rho \frac{1}{n}D'u + \frac{1}{n}D'e.$$

Tomamos plim. Como D está sorteada, no correlaciona con nada ($E(D'A) = E(D'u) = E(D'e) = 0$) y solo sobrevive el término de D :

$$E(D'Y) = (\beta + \rho\gamma) E(D'D) + (\rho\pi + \theta) \underbrace{E(D'A)}_{=0} + \rho \underbrace{E(D'u)}_{=0} + \underbrace{E(D'e)}_{=0} = (\beta + \rho\gamma) V(D).$$

Dividiendo por $E(D'D) = V(D)$:

$$\text{plim } \hat{\beta}_D = \beta + \rho\gamma.$$

El resultado es el efecto total de las horas de pantalla en el bienestar. El directo β más el indirecto vía sueño $\rho\gamma$. El sorteo alcanza porque D no correlaciona con la variable omitida A al estar aleatorizada, de modo que no genera sesgo.

(b) Con el control

Ahora regresamos Y sobre $[D \ C]$, con A omitida. Por Frisch–Waugh–Lovell, el coeficiente de D se obtiene residualizando D y Y respecto de C mediante $M_C = I - C(C'C)^{-1}C'$, y es la covarianza sobre la varianza de las variables residualizadas:

$$\text{plim } \hat{\beta}_D = \frac{\text{Cov}(\tilde{D}, \tilde{Y})}{V(\tilde{D})} = \frac{E(D'M_C Y)}{E(D'M_C D)},$$

donde $\tilde{D} = M_C D$ e $\tilde{Y} = M_C Y$ son los residuos de regresar D e Y sobre C . En el numerador reemplazamos $Y = \beta D + \rho C + \theta A + e$ y distribuimos:

$$E(\tilde{D}'Y) = \beta E(\tilde{D}'D) + \rho E(\tilde{D}'C) + \theta E(\tilde{D}'A) + E(\tilde{D}'e).$$

El segundo término se anula porque $\tilde{D}$ es ortogonal a C ($E(\tilde{D}'C) = 0$), y el último término porque no correlaciona con D . Quedan:

$$E(\tilde{D}'Y) = \beta E(\tilde{D}'D) + \theta E(\tilde{D}'A).$$

El primer término se convierte en $E(\tilde{D}'D) = V(\tilde{D})$. Lo mismo hacemos con el término en el denominador del cociente. El segundo se puede reemplazar por $\tilde{D} = D - \phi C$:

$$E(\tilde{D}'A) = E(D'A) - \phi E(C'A) = -\phi \pi V(A),$$

ya que $E(D'A) = 0$ por el sorteo, pero $E(C'A) = \pi V(A)$ porque el sueño sí correlaciona con el malestar. De esta forma se introduce el sesgo. Dividiendo numerador por denominador y separando en dos:

$$\text{plim } \hat{\beta}_D = \frac{\beta V(\tilde{D}) - \theta \phi \pi V(A)}{V(\tilde{D})} = \beta - \frac{\theta \phi \pi V(A)}{V(\tilde{D})}.$$

Antes de sustituir, calculamos los dos ingredientes. El coeficiente ϕ usa $E(D'C)$, que con $C = \gamma D + \pi A + u$ y el sorteo ($E(D'A) = E(D'u) = 0$) es $E(D'C) = \gamma V(D)$, de modo que

$$\phi = \frac{E(D'C)}{V(C)} = \frac{\gamma V(D)}{V(C)}.$$

La varianza de C , por ser D , A y u mutuamente ortogonales, es $V(C) = \gamma^2 V(D) + \pi^2 V(A) + V(u)$. La varianza del residuo resulta

$$V(\tilde{D}) = V(D) - \phi^2 V(C) = V(D) \frac{V(C) - \gamma^2 V(D)}{V(C)} = V(D) \frac{\pi^2 V(A) + V(u)}{V(C)},$$

donde en el último paso se usó $V(C) - \gamma^2 V(D) = \pi^2 V(A) + V(u)$.

Reemplazamos $\phi = \frac{\gamma V(D)}{V(C)}$ y $V(\tilde{D}) = V(D) \frac{\pi^2 V(A) + V(u)}{V(C)}$ en el sesgo:

$$\frac{\theta \phi \pi V(A)}{V(\tilde{D})} = \frac{\theta \frac{\gamma V(D)}{V(C)} \pi V(A)}{V(D) \frac{\pi^2 V(A) + V(u)}{V(C)}} = \frac{\theta \gamma \pi V(A)}{\pi^2 V(A) + V(u)},$$

donde se cancelan $V(D)$ y $V(C)$. Por lo tanto:

$$\text{plim } \hat{\beta}_D = \beta - \frac{\theta \gamma \pi V(A)}{\pi^2 V(A) + V(u)}.$$

El coeficiente no es el efecto total, ya que controlar por C bloquea el canal vía sueño y no captura $\beta + \rho\gamma$. Pero tampoco es el efecto directo β . Al controlar por el collider C abre una asociación espuria entre D y la omitida A , y el resultado es β más un término de sesgo que no debería estar. El signo de ese sesgo lo fija el numerador $\theta\gamma\pi$. Con los signos esperados $\theta < 0$, $\gamma < 0$ y $\pi < 0$ el producto es negativo y, con el menos delante, el sesgo resulta positivo.

(c) Angrist y Pischke

La derivación anterior es lineal. Angrist y Pischke (2009, §3.2.3) muestran que el mismo problema aparece con outcomes potenciales, sin suponer linealidad. Sea d una dummy sorteada (recibir pantalla o no), c una dummy que responde al tratamiento (dormir bien o mal) e y el bienestar. Cada adolescente tiene versiones potenciales según el valor de d :

$$c = d c_1 + (1 - d) c_0, \quad y = d y_1 + (1 - d) y_0,$$

donde c_1 es si dormiría bien *en caso de recibir pantallas* y c_0 si dormiría bien *en caso de no recibirlas*; análogamente y_1, y_0 son su bienestar en cada caso. De cada adolescente observamos solo una versión, la que corresponde al tratamiento que efectivamente le tocó. Nunca sabremos como habría dormido X sin pantalla esa noche cuando le tocó una. La tentación es comparar el bienestar entre tratados y no tratados mirando solo a los que duermen bien ($c = 1$), es decir, limpiando el efecto del sueño porque todos durmieron bien:

$$E[y \mid c = 1, d = 1] - E[y \mid c = 1, d = 0].$$

Entre los tratados ($d = 1$) lo observado es la versión “1”: $c = c_1$ e $y = y_1$. Entonces “duermen bien” significa $c_1 = 1$, dormirían bien aun recibiendo pantallas, y

$$E[y \mid c = 1, d = 1] = E[y_1 \mid c_1 = 1].$$

Entre los no tratados ($d = 0$) lo observado es la versión “0”: $c = c_0$ e $y = y_0$. Ahí “duermen bien” significa $c_0 = 1$, duermen bien en su vida normal, sin pantallas, y

$$E[y \mid c = 1, d = 0] = E[y_0 \mid c_0 = 1].$$

Los dos subgrupos son personas distintas. $\{c_1 = 1\}$ son los que aguantarían la pantalla sin perder el sueño (chicos físicamente resistentes), mientras que $\{c_0 = 1\}$ son los que duermen bien en condiciones normales (cualquiera). Como el sueño responde a las pantallas, no son el mismo grupo. Restando ambas igualdades:

$$E[y \mid c = 1, d = 1] - E[y \mid c = 1, d = 0] = E[y_1 \mid c_1 = 1] - E[y_0 \mid c_0 = 1].$$

Cambian dos cosas a la vez. El bienestar potencial (y_1 frente a y_0) y el subgrupo de chicos ($c_1 = 1$ frente a $c_0 = 1$). Por eso esta diferencia no puede leerse como “el efecto de las pantallas”. Agregamos el término $E[y_0 \mid c_1 = 1]$, el bienestar sin pantallas de los chicos resistentes ($c_1 = 1$), sumándolo y restándolo, lo que no altera la igualdad:

$$= \left(E[y_1 \mid c_1 = 1] - E[y_0 \mid c_1 = 1] \right) + \left(E[y_0 \mid c_1 = 1] - E[y_0 \mid c_0 = 1] \right).$$

En el primer paréntesis el subgrupo queda fijo (los resistentes, $c_1 = 1$) y solo cambia el tratamiento; en el segundo, el bienestar potencial queda fijo (y_0 , sin pantallas) y solo cambia el subgrupo. Reagrupando el primero como una diferencia de potenciales sobre la misma gente:

$$E[y \mid c = 1, d = 1] - E[y \mid c = 1, d = 0] = \underbrace{E[y_1 - y_0 \mid c_1 = 1]}_{\text{efecto causal en los resistentes}} + \underbrace{E[y_0 \mid c_1 = 1] - E[y_0 \mid c_0 = 1]}_{\text{sesgo de selección}}.$$

El primer término, $E[y_1 - y_0 \mid c_1 = 1]$, es el efecto causal de las pantallas sobre el bienestar, pero solo para los chicos que dormirían bien aun tratados ($c_1 = 1$): compara a la misma gente con y sin pantallas, así que es un efecto causal legítimo, aunque de un subgrupo particular. El segundo, $E[y_0 \mid c_1 = 1] - E[y_0 \mid c_0 = 1]$, es un sesgo de selección. Compara el bienestar sin pantallas de dos grupos de chicos distintos, los resistentes frente a los que duermen bien normalmente, que de base no tienen por qué rendir igual. La diferencia no da cero aunque $y_1 = y_0$ para todos. Si las pantallas no afectaran el bienestar, el primer término se anularía, pero el segundo seguiría vivo, porque condicionar en “duerme bien” selecciona chicos distintos entre tratados y no tratados. Es decir, controlar por el sueño fabrica una diferencia observada aunque las pantallas no tengan ningún efecto: la versión no lineal del sesgo de colisionador de (b).

(d) Simulación

Generamos $R = 500$ réplicas con el DGP $C = -0,5D - 0,5A + u$ e $Y = -0,05D + 0,10C - 0,30A + e$ ($n = 2000$), y en cada una corremos las tres regresiones: Y sobre D ; sobre D y C ; y sobre D , C y A (la que en la práctica no se puede correr, porque A no se observa).

Cuadro 2: El control tentador, $n = 2000$, $R = 500$.

Regresión	Fórmula	Teórico	Prom. sim.	MCse	R^2 prom.
$Y \sim D$	$\beta + \rho\gamma$	-0.1000	-0.0994	0.00061	–
$Y \sim D, C$	$\beta - \frac{\theta\gamma\pi V(A)}{\pi^2 V(A) + V(u)}$	0.0250	0.0256	0.00065	0.187
$Y \sim D, C, A$	β	-0.0500	-0.0499	0.00059	–

Al controlar por C , el coeficiente de D pasa de $-0,10$ (efecto total, que el sorteo estima sin sesgo) a $+0,025$, cambiando incluso de signo: el control por el colisionador introduce un sesgo grande y da la impresión de que las pantallas mejoran el bienestar. Esto no se arregla con más datos: al repetir la segunda regresión con $n = 10000$ el coeficiente permanece en $\approx 0,025$, porque es sesgo de especificación, no ruido muestral que se promedie con el tamaño. De las tres regresiones reportaría la primera ($Y \sim D$): al estar D aleatorizada, estima el efecto causal total sin necesidad de controles. La segunda responde a una pregunta mal planteada (condiciona en un mediador que además es colisionador) y la tercera recuperaría el efecto directo $\beta = -0,05$, pero exige observar A , lo que no es posible en la práctica.