



Primer Trabajo Práctico - Economía Aplicada

Maestría en Economía - Universidad de San Andrés

Luca Armelini

18 de Agosto de 2026

1.1

Se emplea el histórico de nombres publicado por el RENAPER, tal como propone el enunciado. El desarrollo de este trabajo práctico se realiza en la plataforma STATA.

1.2

a) La base cuenta con 9.761.609 filas y 3 columnas. Cada fila corresponde a una combinación nombre-año, y las columnas son las tres variables; el nombre, la cantidad de inscripciones registradas con ese nombre en ese año, y el año. El período abarca desde 1922 en adelante. La importación se realizó con la opción *bindquote(strict)*, que respeta los nombres que contienen comas y vienen entre comillas en el archivo crudo. Con un parseo ingenuo *bindquote(no bind)*, esos nombres se parten y aparecen columnas espurias.

Cuadro 1: Comparación de la lectura del archivo crudo según el tratamiento de las comillas

	Parseo estricto	Parseo ingenuo	Diferencia
Filas	9,761,609	9,761,609	0
Columnas	3	5	2

b) Empleamos el comando *describe* en Stata, con el fin de observar el tipo con el que queda importada cada variable. Como se observa en el Cuadro 2, la columna **nombre** viene en formato de texto (**str103**), lo cual es consecuente con lo que se quiere medir. **cantidad** y **anio** quedaron como numéricas enteras (**int**). La primera es un conteo de inscripciones y la segunda, el año de registro, ambas numéricas. Por lo tanto, la importación asignó correctamente los tipos.

Cuadro 2: Tipo de almacenamiento de cada variable en la base cruda

Variable	Tipo
nombre	str103 (texto)
cantidad	int (numérica)
anio	int (numérica)

c) En la base cruda hay 3.439.832 nombres distintos. Para determinarlo se emplea el comando **egen tag = tag(nombre)**, que marca con un 1 exactamente una fila por cada nombre distinto (y con 0 las repeticiones); al sumar esas marcas se obtiene la cantidad de nombres únicos. Cabe destacar que este número está sobre-dimensionado porque cada grafía del mismo nombre se cuenta por separado (“MARIA”, “María” y “maria” figuran como tres distintos). El período cubierto va de 1922 a 2015. En cuanto a faltantes, **cantidad** y **anio** no tienen ninguno, mientras que **nombre** presenta 8 registros con cadena vacía.

d) La clave (nombre crudo, año) es única en términos de duplicados. **duplicates report nombre anio** muestra que las 9.761.609 filas corresponden a combinaciones (nombre, año) distintas, sin ninguna repetición.

1.3

a) Para corregir los espacios sobrantes se genera una nueva variable `nombre_norm`, copia de `nombre`, sobre la cual se aplican todas las reglas de normalización de forma sucesiva (conservando `nombre` original para poder contar cuántas filas se modifican por paso). La regla combina dos funciones de Stata. `strtrim()`, que elimina los espacios al principio y al final del nombre, e `itrim()`, que colapsa las secuencias de espacios internos repetidos a uno solo. Formalmente se ejecuta `replace nombre_norm = itrim(strtrim(nombre_norm))`. Esta regla modifica 304.931 filas.

b) Para unificar nombres que difieren solo en el uso de mayúsculas y minúsculas (“MARIA”, “Maria” y “maria”), se lleva todo el nombre a minúsculas con la función `ustrlower()`: `replace nombre_norm = ustrlower(nombre_norm)`. Se emplea `ustrlower()` y no `lower()` porque esta última deja sin modificar las vocales acentuadas en mayúscula (Á, É, etc.). Se opta por convertir todo a minúsculas porque es óptimo como clave de agrupación. Un nombre de texto tiene una infinidad de reglas ortográficas que solo pueden ser diferenciadas caso a caso. La regla modifica 9.761.562 filas, prácticamente la totalidad de la base, dado que el registro crudo viene mayoritariamente con alguna mayúscula.

c) Las tildes y diéresis se eliminan porque solo alteran la grafía de una misma letra y no el propio nombre. Se optó por un método basado en normalización Unicode. Se descompone cada carácter acentuado en su letra base más el diacrítico por separado, y luego se borran todos los diacríticos de una sola vez. Esto captura de un mismo paso las tres familias de acentuación; agudas propias del español (á, é, í, ó, ú), graves propias del francés o el italiano (à, è, ì, ò, ù), incluidas por la cantidad de inmigrantes que recibió el país, y diéresis (ü, ä, ë, ï, ö), aun cuando solo ü es propia del español. Previamente se reparan caracteres mal decodificados provenientes de una codificación legacy del archivo original (por ejemplo “fab{i}an” o “mart{i}n”, que corresponden a “fab{i}án” y “mart{i}n”). La regla modifica 396.380 filas. Por su parte, la ñ no es una “n” acentuada sino una letra propia del español. Convertirla en “n” fusionaría nombres diferentes (“Begoña” pasaría a “begona”), introduciendo colapsos falsos que sesgarían el conteo de inscripciones por nombre. Por eso se preserva la ñ intacta. Se la reemplaza por un marcador temporal antes de la descomposición y se la restaura al final, protegiendo las 5.002 filas que la contienen.

d) Se elimina la puntuación que queda colgando al final del nombre, como en “josé.”. La regla utiliza `ustrregexra()` para borrar cualquier secuencia final de signos de puntuación y espacios, y luego se aplica `strtrim()` por si quedó algún espacio. Se optó por limpiar solo la puntuación final, y no todo punto en cualquier posición, porque un diagnóstico previo mostró que había 2.893 nombres con punto al final frente a 2.946 con punto en cualquier lugar. Apenas 53 casos tenían puntos internos, que se descartan en el paso siguiente por contener dígitos o símbolos espurios. La regla modifica 2.987 filas.

e) Antes de descartar, se aplica un último paso de limpieza. Los guiones y apóstrofes se convierten en espacio (`subinstr`), de modo que grafías como “matilde-raquel” o “d’anne” se unifiquen con sus versiones separadas por espacio; esto modifica 493 filas. Hecho lo anterior, se descartan las filas que no corresponden a un nombre según un criterio único. Se elimina toda fila vacía, con dígitos, o que contenga cualquier carácter que no sea una letra minúscula, la ñ o un espacio. Este criterio captura los tres tipos de basura detectados: registros vacíos (13), anotaciones administrativas con números como DNIs y restos con símbolos espurios como paréntesis de “(h)”, barras o guiones bajos. En total se descartan 1.331 filas, quedando la base en 9.760.278 registros. La verificación posterior confirma que no queda ninguna fila con caracteres no válidos.

f) La normalización unifica grafías que en el archivo crudo aparecen escritas de formas muy diversas. El Cuadro 3 muestra los tres nombres normalizados que más grafías crudas colapsan:

Cuadro 3: Grafías con más colapsos

Nombre normalizado	N.º de grafías	Ejemplo de grafía cruda
maria de los angeles	67	MARIA DE LOS ANGELES
maria del carmen	42	Maria Del Carmen
maria de los milagros	29	Maria De Los Milagros

1.4

a) Se colapsa la base a nivel nombre normalizado $\times$ año sumando las inscripciones, mediante `collapse (sum) cantidad, by(nombre_norm anio)`. Así, grafías distintas de un mismo nombre en un mismo año se funden en una sola fila sumando sus cantidades. La base queda con 9.576.267 filas, partiendo de 9.760.278. La reducción es pequeña, lo que a primera vista sorprende, pero se explica por la estructura de los datos. La base tiene muchos nombres compuestos sumamente específicos, lo que hace que al colapsar nombres no se reduzcan tantas filas.

b) Se verifica la clave única mediante un bloque que aborta si falla. Tres `assert` (sin faltantes en `nombre_norm` ni `anio`, sin cadenas vacías) seguidos de `isid nombre_norm anio`, que detiene el script con error ante cualquier duplicado. El chequeo se supera sin abortar. La clave es única, sin duplicados ni faltantes.

c) Se construye el total anual de inscripciones colapsando la base por año en una tabla auxiliar (`collapse (sum) total_anual = cantidad, by(anio)`) y se la pega a la base principal con `merge m:1 anio`. La verificación del pegado es doble: se exige con `assert` que todas las filas hagan match (`_merge==3`, sin filas sin correspondencia) y que el número de observaciones sea idéntico antes y después, garantizando que el merge no pierde ni duplica filas. Ambas condiciones se cumplen. Las 9.576.267 filas matchean y el conteo se preserva. Con el total pegado se calcula la participación de cada nombre como `cantidad / total_anual`. Como control, se verifica que la participación esté en el intervalo $(0, 1]$ y que, sumada dentro de cada año, dé 1. Suma 1 en los 94 años de la serie.

d) Se conforma la base final quedándose con las cinco variables relevantes (`nombre_norm`, `anio`, `cantidad`, `total_anual` y `participacion`), ordenada por la clave `nombre $\times$ año`. Se descarta el nombre crudo original, que solo cumplía la función de permitir el conteo de filas modificadas en cada paso de la normalización.




Figura 1: Evolución de la popularidad del nombre *Luca*, Argentina 1924–2015.

La Figura 1 muestra la cantidad de inscripciones del nombre *Luca* cada 10.000 habitantes inscritos. Este ejercicio se realiza desde 1924 hasta 2015. Se observa una popularidad sumamente baja del nombre hasta los años 90, donde comienza a crecer exponencialmente hasta llegar a 9 de cada 10.000 inscritos alrededor del 2010.

1.6

Se define una variable $D_t \in \{0, 1\}$ que clasifica los años tratados como aquellos en que Argentina jugó un mundial (1930, 1934, 1958, 1962, 1966, 1974, 1978, 1982, 1986, 1990, 1994, 1998, 2002, 2006, 2010 y 2014), y como control aquellos en que no lo hizo. De esta forma, se tienen 16 años tratados y 78 de control. Se excluyen del grupo tratado los Mundiales sin Argentina: 1938, 1950 y 1954 (ausencias por boicot y decisiones políticas de la AFA) y 1970 (única eliminación por vía clasificatoria); también quedan fuera 1942 y 1946, cancelados por la Segunda Guerra Mundial. El criterio se apoya en la hipótesis de que un Mundial solo podría influir sobre la elección de nombres cuando genera euforia local, lo que requiere la presencia de la selección.

Se restringe la muestra a los nombres con al menos 10.000 inscripciones históricas, descartando la extensa cola de nombres poco frecuentes. Sobre la base filtrada se rellena con ceros, para cada nombre, los años en que no registró inscripciones (mediante `tsfill`), de modo que el panel quede balanceado con una observación por nombre y año.

a) Este trabajo examina si los Mundiales de fútbol con participación argentina inciden sobre la elección de nombres inscritos. Clasificando los años del período 1922–2015 según haya habido o no un Mundial con Argentina, y midiendo la popularidad de cada nombre por su participación anual, se estima para cada nombre la diferencia de medias en su participación entre años tratados y de control. Los nombres con asociación más

fuerte; *María Ester*, seguido de *Alicia* y *Marta*; presentan una participación significativamente menor en los años mundialistas que en el resto, siendo *María Ester* el hallazgo principal por registrar el estadístico t de mayor magnitud. En el otro extremo aparece *Emiliano* como el que más sube, sin ser significativo.

b)




Figura 2: Participación media de *María Ester* en años tratados (Mundial con Argentina) y de control, con intervalos de confianza al 95 %.

1.7

a) La diferencia de medias no identifica necesariamente el efecto causal de D_t . Siguiendo la descomposición vista en clases, la diferencia de medias observada se descompone como:

$$\underbrace{E[Y | D = 1] - E[Y | D = 0]}_{\text{diferencia observada}} = \underbrace{E[Y_1 | D = 1] - E[Y_0 | D = 1]}_{\text{efecto del tratamiento (ToT)}} + \underbrace{E[Y_0 | D = 1] - E[Y_0 | D = 0]}_{\text{sesgo de selección}}.$$

La diferencia observada coincide con el efecto causal únicamente si el sesgo de selección es nulo, es decir, si $E[Y_0 | D = 1] = E[Y_0 | D = 0]$. Los años tratados y de control deberían tener la misma popularidad en ausencia de tratamiento. Esto requiere que D_t sea independiente de los determinantes de la popularidad ($D_t \perp Y_0$).

En el diseño ese supuesto se viola. Los 16 años tratados se concentran en décadas recientes (doce de ellos posteriores a 1974), mientras que los de control abarcan todo el siglo. Como la popularidad de cada nombre sigue una fuerte tendencia secular, nombres tradicionales como *María Ester* declinan en el tiempo, los años tratados tienen menor Y_0 para esos nombres que los de control. El sesgo de selección es entonces negativo y no nulo. La diferencia de medias captura la tendencia temporal de la moda de nombres, no un efecto de los mundiales. Para interpretarla causalmente habría que suponer que la ocurrencia de un Mundial es independiente de todo otro determinante de la popularidad de los nombres, supuesto insostenible dado que los Mundiales están correlacionados con el paso del tiempo.

b) Se repite el barrido en dos variantes con el fin de contrastar el barrido original.

(i) *Cantidad de inscripciones*: Se cambia la participación anual del nombre por la cantidad de veces que ese nombre fue inscrito en cada año. El nombre con mayor $|t|$ pasa a ser *Luisa* ($t = -2,70$), y el resto del ranking vuelve a estar conformado por nombres tradicionales (Marta, Elvira, Elsa). Cambia el nombre más castigado por el tratamiento y la magnitud del estadístico respecto al caso original, aunque el patrón observado de nombres antiguos en declive se mantiene.

(ii) *Tratamiento placebo*: Reasignando al azar los 16 años tratados, el $|t|$ máximo alcanza $-4,25$ (*Daiana Soledad*), superando al del tratamiento inicial. Esto muestra que buscar el máximo $|t|$ entre cientos de nombres produce estadísticos extremos por azar, con independencia de que exista un efecto real. Por tanto, el hallazgo original resulta indistinguible de lo que genera un tratamiento inventado.

c) Previo a formular las tres hipótesis, es importante destacar que los datos no permiten corroborar ninguna de ellas, ya que hay un no observable, el resultado potencial de los años tratados sin tratamiento, que conduce a un sesgo de selección. Este se puede defender, pero no demostrar. Dicho lo anterior, tres hipótesis compatibles pueden ser:

(i) *Efecto Mundialista*: Propuesta como hipótesis inicial. La fiebre mundialista hace que nombres asociados al mundo del fútbol sean más populares en años en los que se efectúa dicha competencia y Argentina participa. Paralelamente, nombres poco vinculados al mundo futbolístico, como *María Ester*, bajan en cantidad de inscripciones en años tratados.

(ii) *Efecto Secular*: Considerando que Argentina jugó más mundiales en el periodo 1974-2014 (11) que en el periodo 1922-1974 (5), existe un efecto secular no menor. Nombres como *María Ester*, *Marta* o *Elvira* se ven penalizados debido a que el tratamiento está más asociado a tiempos recientes, y estos son nombres propios de generaciones pasadas.

(iii) *Efecto de apertura cultural*: El mundial abre al público argentino nombres de jugadores foráneos de otros equipos, lo que produce un aumento de dichos nombres en desmedro de nombres locales tradicionales.

Estas tres hipótesis no pueden distinguirse con estos datos. Las tres predicen exactamente la misma diferencia de medias observada. La hipótesis secular es indistinguible de las causales porque el tratamiento está casi perfectamente confundido con el paso del tiempo, y las dos causales (fútbol y apertura cultural) son indistinguibles entre sí porque ambas predicen una caída de los nombres tradicionales por mecanismos que la base no permite separar.

d) Si cada estudiante publica solo su mejor t , la distribución queda corrida hacia los extremos, y no como la campana de un t normal centrada en 0. El razonamiento es el siguiente. Con la distribución de t centrada en 0, la mayoría de los valores cae entre -2 y 2 , resultando no significativos. No obstante, al calcular un t para cada uno de cientos de nombres, algunos valores superan ese umbral por puro azar, y son justamente esos los que se reportan como los mejores. Ese nombre no tiene ninguna interpretación causal. Es simplemente un subproducto de calcular muchos t distintos y quedarse con el máximo. Esto es el sesgo de publicación. El umbral $|t| > 2$ controla el falso positivo de una prueba; al elegir el máximo entre cientos, esa garantía se pierde y un t grande deja de ser evidencia de nada. El supuesto hallazgo real ($t = -3,16$) es indistinguible del placebo aleatorio ($t = -4,25$), que no encierra ningún efecto. Publicar solo el mejor t genera hallazgos significativos que son puro ruido de la búsqueda.