

Trabajo Práctico 2: Testeo múltiple

Economía Aplicada

Luca Armelini

25 de agosto de 2026



La Tabla 2

a) El presente inciso reporta las 21 regresiones del experimento sobre 21 variables de interés distintas. El Cuadro 1 muestra, para cada medida, el coeficiente de *treat*, su error estándar agrupado por municipio, el *p*-valor sin ajustar y el número de observaciones.

Cuadro 1: Efecto del tratamiento sobre las 21 medidas de la Tabla 2

Medida	Coef.	EE	p-valor	N
<i>Panel A. Habilidades cognitivas y de lenguaje</i>				
Cognición (Bayley)	0.250***	(0.063)	0.000	1263
Lenguaje receptivo (Bayley)	0.174***	(0.063)	0.007	1263
Lenguaje expresivo (Bayley)	0.029	(0.062)	0.644	1262
Motor fino (Bayley)	0.073	(0.059)	0.224	1261
Vocabulario (MacArthur)	0.086	(0.064)	0.179	1321
Frases (MacArthur)	0.057	(0.056)	0.315	1321
<i>Panel B. Habilidades socioemocionales</i>				
Dificultad (Bates)	0.073	(0.045)	0.107	1325
Insociabilidad (Bates)	0.037	(0.055)	0.506	1325
Inquietud (Bates)	0.031	(0.054)	0.569	1325
Control inhibitorio (Rothbart)	0.000	(0.058)	1.000	1322
Atención (Rothbart)	0.072	(0.048)	0.136	1322
<i>Panel C. Inversión material de los padres</i>				
Variedad de materiales (FCI)	0.217***	(0.064)	0.001	1325
Libros para pintar	-0.124**	(0.056)	0.028	1325
Juguetes que se mueven	-0.049	(0.065)	0.452	1325
Juguetes de formas	0.426***	(0.088)	0.000	1325
Juguetes comprados	0.020	(0.061)	0.750	1325
<i>Panel D. Inversión de tiempo de los padres</i>				
Variedad de actividades (FCI)	0.280***	(0.051)	0.000	1325
Contar cuentos	0.153**	(0.064)	0.019	1325
Leer	0.403***	(0.068)	0.000	1325
Jugar con juguetes	0.183***	(0.060)	0.003	1325
Nombrar cosas	0.144***	(0.048)	0.004	1325

Nota: cada fila es una regresión con su línea de base, sexo del niño y efectos fijos de evaluador (Bayley) o entrevistador (resto). Errores estándar agrupados por municipio entre parentesis. *p* sin ajustar por multiplicidad. * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

b) De las 21 regresiones efectuadas, 10 medidas rechazan la hipótesis nula al 5 %: dos en habilidades cognitivas y de lenguaje, tres en inversión material de los padres y cinco en inversión de tiempo de los padres. Si el programa no tuviese ningún efecto sobre ninguna de las 21 medidas, cada test rechazaría al 5 % con probabilidad 0,05 puramente por azar. Así, al realizar 21 tests independientes, se tendrían $21 \times 0,05 = 1,05$ rechazos espurios esperados. Dado que en el Cuadro 1 se rechaza la nula para 10 medidas, no puede descartarse que alguno de esos rechazos sea producto del azar.

Las correcciones

a) Se calculan los p -valores ajustados por Bonferroni y Holm. Bonferroni multiplica cada p -valor por el número de test de la familia ($p \times 21$, con tope en 1), aplicando el mismo umbral a todas las hipótesis. Holm mejora esa lógica con un procedimiento secuencial: ordena los p -valores de menor a mayor y exige un umbral cada vez menos estricto, por lo que nunca rechaza menos que Bonferroni. Bajo estas correcciones, de los 10 rechazos originales al 5 % sobreviven 5 (Bonferroni) y 6 (Holm). El detalle completo, junto con el resto de las correcciones, se reporta en el Cuadro 2.

b) Se calculan los p -valores de Romano–Wolf sobre la misma familia de 21 medidas, con $B = 1000$ remuestras y semilla 20260812, remuestreando municipios enteros para respetar el diseño de aleatorización. A diferencia de Bonferroni y Holm, que asumen la peor dependencia posible, Romano–Wolf aprovecha la correlación entre las medidas. Los resultados se reportan en el Cuadro 2.

c) Se vuelve a aplicar Romano–Wolf tomando el panel D (inversión de tiempo de los padres) en lugar de las 21 medidas, con los mismos parámetros. Al reducir la familia de 21 a 5 hipótesis, la corrección se vuelve menos exigente: las cinco medidas del panel rechazan la nula al 5 %, frente a solo dos cuando la familia son las 21 medidas. Ambas definiciones de familia se comparan en el Cuadro 2.

d) Se presentan en el Cuadro 2 el efecto de cada medida, su error estándar, el p -valor sin ajustar y los p -valores ajustados por los tres métodos, bajo las dos definiciones de familia.

Cuadro 2: Efecto del tratamiento y correcciones por multiplicidad

Medida	Coef.	EE	p crudo	p Bonf.	p Holm	p RW (21)	p RW (D)
<i>Panel A. Cognitivo y de lenguaje</i>							
Cognición (Bayley)	0.250	(0.063)	0.000***	0.003***	0.002***	0.012**	–
Lenguaje receptivo (Bayley)	0.174	(0.063)	0.007***	0.147	0.098*	0.122	–
Lenguaje expresivo (Bayley)	0.029	(0.062)	0.644	1.000	1.000	0.969	–
Motor fino (Bayley)	0.073	(0.059)	0.224	1.000	1.000	0.834	–
Vocabulario (MacArthur)	0.086	(0.064)	0.179	1.000	1.000	0.806	–
Frases (MacArthur)	0.057	(0.056)	0.315	1.000	1.000	0.923	–
<i>Panel B. Socioemocional</i>							
Dificultad (Bates)	0.073	(0.045)	0.107	1.000	1.000	0.689	–
Insociabilidad (Bates)	0.037	(0.055)	0.506	1.000	1.000	0.969	–
Inquietud (Bates)	0.031	(0.054)	0.569	1.000	1.000	0.969	–
Control inhibitorio (Rothbart)	0.000	(0.058)	1.000	1.000	1.000	1.000	–
Atención (Rothbart)	0.072	(0.048)	0.136	1.000	1.000	0.747	–
<i>Panel C. Inversion material</i>							
Variedad de materiales (FCI)	0.217	(0.064)	0.001***	0.020**	0.016**	0.038**	–
Libros para pintar	-0.124	(0.056)	0.028**	0.587	0.335	0.342	–
Juguetes que se mueven	-0.049	(0.065)	0.452	1.000	1.000	0.969	–
Juguetes de formas	0.426	(0.088)	0.000***	0.000***	0.000***	0.002***	–
Juguetes comprados	0.020	(0.061)	0.750	1.000	1.000	0.969	–
<i>Panel D. Inversion de tiempo</i>							
Variedad de actividades (FCI)	0.280	(0.051)	0.000***	0.000***	0.000***	0.001***	0.001***
Contar cuentos	0.153	(0.064)	0.019**	0.398	0.246	0.274	0.035**
Leer	0.403	(0.068)	0.000***	0.000***	0.000***	0.001***	0.001***
Jugar con juguetes	0.183	(0.060)	0.003***	0.060*	0.045**	0.073*	0.023**
Nombrar cosas	0.144	(0.048)	0.004***	0.074*	0.053*	0.083*	0.023**

Nota: efecto de treat en desvíos estándar; EE por municipio entre parentesis. Bonferroni, Holm y RW (21): familia = 21 medidas. RW (D): familia = 5 del panel D. Romano–Wolf con $B=1000$, semilla 20260812, remuestreo de municipios. * $p < .10$, ** $p < .05$, *** $p < .01$.

e) De las 10 medidas significativas al 5 % sin corregir, solo cinco sobreviven a las tres correcciones sobre la familia de 21. Estas son cognición, variedad de materiales, juguetes de formas, variedad de actividades y lectura, es decir, los efectos con p crudos más pequeños. Los rechazos limítrofes no resisten, ya que eran candidatos a ser producto de la multiplicidad. La conclusión sustantiva se mantiene, el programa afecta el desarrollo cognitivo y la inversión de los padres, pero se reduce a los canales más robustos.

No obstante, cambiar la definición de familia altera el resultado. Con las 21 medidas como familia, en el panel D solo rechazan variedad de actividades y lectura; al tomar el panel D como familia (5 hipótesis), rechazan las cinco. Al corregir por menos hipótesis, el umbral se vuelve menos exigente y las medidas medianas del panel sobreviven. La definición de familia modifica la propia conclusión.

Por último, Holm nunca rechaza menos que Bonferroni porque aplica al p -valor más pequeño el mismo umbral que Bonferroni (α/m), y a partir de ahí usa umbrales cada vez menos estrictos ($\alpha/(m+1-k)$). Domina a Bonferroni sin supuestos adicionales.

Achicar la familia: el índice de Anderson

a) Las cinco medidas del panel D miden inversión de tiempo de los padres, de modo que un valor más alto es mejor en todas. En la matriz de correlaciones de las medidas de seguimiento se confirma que todos los pares correlacionan positivamente, por lo que ninguna requiere inversión de signo. Para poder agregar las cinco medidas en un único índice es necesario expresarlas en una escala común. Cada medida se estandariza restando la media y dividiendo por el desvío estándar del *grupo de control*: $\tilde{y}_{ij} = (y_{ij} - \bar{y}_j^C) / \sigma_j^C$. Se usa el grupo control como referencia, así cada valor se interpreta como desvíos respecto de un niño no tratado, y la vara de medición no queda contaminada por el propio efecto del tratamiento. Luego de estandarizar, se agregan las medidas ponderando por la covarianza inversa, de modo que aquellas más correlacionadas con el resto reciben menor ponderación, al aportar información redundante, e incluso pesos negativos. En este caso, la variedad de actividades (*fci_play_act*), que correlaciona en torno a 0,5 con las otras cuatro medidas, recibe el único peso negativo, mientras que jugar y nombrar reciben los pesos más altos.

b) Se estima el efecto del tratamiento sobre el índice con la misma especificación del Ejercicio 1. El programa aumenta la inversión de tiempo de los padres en 0,21 desvíos estándar ($p < 0,001$), en un único test que no requiere corrección por multiplicidad. El Cuadro 3 reporta la estimación.

Cuadro 3: Efecto del tratamiento sobre el índice de Anderson (panel D)

	Índice inversion de tiempo
Efecto del tratamiento	0.212*** (0.039)
p -valor	0.000
Observaciones	1325

Nota: índice de covarianza inversa de Anderson (2008) sobre las 5 medidas del panel D. Misma especificación que el Ejercicio 1: línea de base del bloque, sexo, FE de entrevistador, errores agrupados por municipio. Error estándar entre parentesis. * $p < .10$, ** $p < .05$, *** $p < .01$.

c) Ambas agregaciones coinciden en la conclusión. El índice de covarianza inversa arroja un efecto de 0,212 desvíos estándar ($p < 0,001$), y el factor latente de inversión de tiempo reportado en la Tabla 2 de [Attanasio, Cattán, Fitzsimons, Meghir, y Rubio-Codina \(2020\)](#) da 0,302 log points, también altamente significativo. Aunque las magnitudes no son directamente comparables debido a que el

índice se expresa en desvíos estándar y el factor en *log points*, ambas rutas confirman que el programa aumentó la inversión de tiempo de los padres.

Dos formas de agregar las mismas medidas pueden diferir porque asignan pesos distintos a cada componente. El índice de Anderson penaliza las medidas redundantes mediante la covarianza inversa, mientras que el factor latente privilegia la variación común a todas. Si el efecto del tratamiento se concentrara en una medida que un método pondera alto y el otro bajo, las inferencias podrían divergir. En este caso coinciden porque el efecto está repartido de forma pareja entre las cinco medidas del panel.

Referencias

Attanasio, O., Cattan, S., Fitzsimons, E., Meghir, C., y Rubio-Codina, M. (2020). Estimating the production function for human capital: Results from a randomized controlled trial in colombia. *American Economic Review*, 110(1), 48–85. doi: 10.1257/aer.20150183