Trabajo Práctico 8

Inferencia en un experimento sorteado por escuelas

Luca Armelini

Economía Aplicada

Universidad de San Andrés

20 de octubre de 2026

1 El sorteo

a) El Cuadro 1 describe el sorteo del año 2000 hecho en las escuelas israelíes. Hay 3.821 alumnos en 39 escuelas, 20 tratadas y 19 de control, agrupadas en 19 pares. El tamaño de las escuelas varía mucho. Entre 9 y 248 alumnos, con una mediana de 96. Dieciocho pares tienen dos escuelas, mientras que un solo par tiene tres, dos tratadas y una de control. Este par refleja la escuela de control que, según reportan los autores, cerró.

Cuadro 1: El sorteo del 2000

	2001
Pares	19
Escuelas	39
Tratadas	20
Control	19
Alumnos	3821
Alumnos por escuela	
Mínimo	9
Mediana	96
Máximo	248
Pares según cantidad de escuelas	
Con 1 escuela	0
Con 2 escuelas	18
Con 3 escuelas	1

Nota: Alumnos de último año de 2001, agregados a nivel escuela. Se reporta la cantidad de pares, escuelas y alumnos, el tamaño de las escuelas y la cantidad de escuelas por par.

b) El tratamiento se sorteó a nivel escuela, dentro de cada par. Por tanto, todos los alumnos de una misma escuela son tratamiento o control. A su vez, los alumnos de una misma escuela comparten docentes, clases, contextos y shocks, lo que provoca que sus errores estén correlacionados. Como además el regresor es idéntico dentro de cada escuela, MCO va a subestimar la varianza de $\hat{\beta}$. Por eso se agrupan los errores estándar por escuela, que es el nivel al que se asignó el tratamiento. En otras palabras, la información sobre el tratamiento viene de las 39 escuelas, no de los 3.821 alumnos de forma independiente. La muestra contiene 34 escuelas con mujeres, por lo que se pierden las 5 que solo tienen varones. De estas 5, 4 son religiosas judías y la otra es árabe. Cuatro son tratadas y una de control. Considerando todo lo anterior, quedan 16 escuelas tratadas y 18 de control en la muestra. Además, cuatro pares (5, 9, 10 y 17) quedan con una sola escuela, y el par 7 pasa a tener dos (antes tenía 3).

c) Como el sorteo se hizo de forma independiente dentro de cada par, la cantidad de asignaciones posibles es el producto, sobre los pares, de las formas de elegir las escuelas tratadas dentro de cada uno:

$$A = \prod_{p=1}^{P} \binom{n_p}{t_p},$$

donde n_p es la cantidad de escuelas del par p y t_p la cantidad de tratadas.

Con todos los alumnos hay 18 pares de dos escuelas con una tratada y un par de tres con dos tratadas:

$$A = \binom{2}{1}^{18}\binom{3}{2} = 2^{18} \cdot 3 = 786.432.$$

En la muestra de mujeres quedan 15 pares de dos escuelas, con una tratada cada uno, y 4 pares con una sola escuela, cuya asignación queda fija:

$$A_{\text{mujeres}} = \binom{2}{1}^{15}\binom{1}{1}^{4} = 2^{15} = 32.768.$$

2 La correlación entre alumnos de una misma escuela

a) En el presente inciso, se estima con los datos de 2001 la regresión:

$$\text{zakaibag}_{ij} = \alpha + \beta\,\text{treated}_j + \gamma_1\,\text{semarab}_j + \gamma_2\,\text{semrel}_j + e_{ij} \tag{1}$$

donde i indexa alumnos y j escuelas. Los tres regresores varían solo entre escuelas. Se procede a guardar el residuo y calcular su correlación intra-cluster con el comando `loneway`. Esta es de $\rho = 0{,}108$. La correlación entre los residuos de dos alumnos de la misma escuela es de 0,11. Dicho de otra manera, aproximadamente un 11 % de la varianza del residuo se explica por la escuela a la que va el alumno.

b) Se integra el factor de Moulton, que propone que si todas las escuelas tienen n alumnos, hay que multiplicar el error estándar de MCO por $[1 + (n-1)\,\rho]^{1/2}$, donde ρ es la correlación intra-cluster del residuo. En este caso, se calcula:

$$[1 + (97{,}97 - 1) \cdot 0{,}108]^{1/2} = 3{,}38.$$

El Cuadro 2 muestra la comparación entre el error estándar de $\hat{\beta}$ por MCO y el agrupado por escuela.

Cuadro 2: Factor de Moulton y errores estándar

Factor de Moulton	
Correlación intra-escuela del residuo (ρ)	0,108
Alumnos por escuela, promedio (n)	97,97
$[1 + (n-1)\rho]^{1/2}$	3,38
Errores estándar de $\hat{\beta}$	
$\hat{\beta}$	0,056
MCO	0,0138
Agrupado por escuela	0,0467
Cociente agrupado / MCO	3,37

Nota: Alumnos de último año de 2001. Regresión de `zakaibag` en `treated`, `semarab` y `semrel`. Se reporta el factor de Moulton y los errores estándar de $\hat{\beta}$ de MCO y agrupado por escuela.

La fórmula de Moulton, con solo dos números (ρ y n), predice casi exactamente cuánto se agranda el error estándar al agrupar, dando un valor de 3,38. Esto es muy similar al cociente entre el error

agrupado y el de MCO, que es de 3,37. No son idénticos porque la fórmula de Moulton supone escuelas del mismo tamaño y errores homocedásticos, mientras que el error agrupado no impone ninguno de esos supuestos y aquí las escuelas tienen entre 9 y 248 alumnos.

c) En este caso ρ_x vale 1, porque todos los alumnos de una escuela tienen el mismo valor de `treated`. Toda la variación del regresor es entre escuelas, no dentro de ellas. Con $\rho_x = 1$, la fórmula queda idéntica a la de Moulton al cuadrado. Incluso si la correlación entre alumnos es chica, hay que pensar que esta se multiplica por la cantidad de compañeros que cada alumno tiene en su escuela. Así, con un promedio de 98 alumnos por escuela, cada alumno correlaciona con 97 más: $1 + 97 \cdot 0{,}108 \approx 11{,}4$, por lo que la varianza se multiplica por 11,4 y el error estándar por 3,4. Por último, si se sorteara alumno por alumno dentro de cada escuela, $\rho_x \approx 0$, ya que dentro de cada escuela habría tratados y controles, y saber que un alumno es tratado no diría nada de su compañero. El factor quedaría en 1 y MCO no subestimaría el error estándar.

3 Cuatro p-valores para las mujeres

a) Se estima la especificación del paper con todos los controles para las mujeres de 2001:

$$\text{zakaibag}_{ij} = \alpha + \beta\, \text{treated}_j + X_{ij}'\gamma + e_{ij}, \tag{2}$$

donde X_{ij} incluye `semarab` y `semrel`, dummies de los cuartiles 2, 3 y 4 de `lagscore`, la educación del padre y de la madre, una dummy de cuatro o más hermanos y `ole5`. Los cuartiles se arman dentro de la muestra de mujeres, con la regla del código de los autores, y no se incluyen efectos de par. Con las 1.861 alumnas de las 34 escuelas se obtiene $\hat{\beta} = 0{,}105$, igual al reportado en la Tabla 2 del paper.

b) El Cuadro 3 muestra los resultados para mujeres y varones.

Cuadro 3: Cuatro p-valores para $H_0 : \beta = 0$, 2001

	Mujeres	Varones
$\hat{\beta}$	0,105	-0,022
Alumnos	1.861	1.960
Escuelas	34	34
Robusto		
p-valor	0,000	0,186
IC 95 %	[0,068; 0,141]	[-0,055; 0,011]
Agrupado por escuela		
p-valor	0,024	0,583
IC 95 %	[0,014; 0,195]	[-0,104; 0,059]
Wild cluster bootstrap		
p-valor	0,039	0,619
IC 95 %	[0,006; 0,203]	[-0,112; 0,069]
Aleatorización		
p-valor	0,085	0,571

Nota: Alumnos de último año de 2001, por sexo, con todos los controles y sin efectos de par. Se reporta $\hat{\beta}$ y, para cada método, el p-valor de $H_0 : \beta = 0$ y el intervalo de confianza del 95 % cuando el método lo da.

Bajo el método robusto, el coeficiente en mujeres es significativo incluso al 1 % ($p = 0{,}000$) y presenta un intervalo angosto, pero ignora la correlación dentro de las escuelas, lo que provoca que se exagere la precisión. Bajo el método agrupado por escuela ($p = 0{,}024$) y el wild bootstrap ($p = 0{,}039$), el resultado sigue siendo significativo al 5 %, pero con intervalos más anchos. Por último, mediante aleatorización ($p = 0{,}085$), que no da intervalo, solo se rechaza al 10 %. Cuanto más abajo en la tabla, menos supuestos hace el método y más se apoya en cómo se generaron los datos. Por eso los p-valores van subiendo.

c) A diferencia del caso de las mujeres, en el caso de los varones el Cuadro 3 muestra un coeficiente negativo y pequeño, $\hat{\beta} = -0{,}022$, igual al reportado en la Tabla 2 del paper. Dicho coeficiente no es significativo bajo ninguno de los cuatro métodos. Por lo tanto, no hay evidencia de que el programa haya tenido efecto sobre los varones.

d) Como se menciona en los incisos anteriores, el efecto positivo en mujeres y la no significancia en varones se mantienen para los cuatro métodos. La diferencia está en que, a medida que se van levantando supuestos desde el método robusto, sube el valor p y aumentan los intervalos de confianza, dado que los métodos reconocen más incertidumbre. Por eso la significancia al 5 % en mujeres depende del método, ya que con aleatorización solo se rechaza al 10 %.

Por su parte, la aleatorización testea como hipótesis nula que el programa no tuvo efecto sobre ninguna alumna, mientras que los otros tres métodos testean que el efecto promedio es cero. Por lo tanto, asigna otro tratamiento y otro control de manera aleatoria dentro de cada par y ve si el coeficiente obtenido es extremo frente a los de esos sorteos. Si se rechaza la hipótesis nula, el tratamiento tuvo efecto sobre al menos alguna alumna. Yo usaría este método porque es el que más supuestos levanta y porque el sorteo se hizo de verdad dentro de pares, aunque tiene en contra que no da intervalo de confianza.

4 Un año sin programa

a) El Cuadro 4 muestra lo efectuado en el inciso anterior, con mujeres del 2000. Se obtiene $\hat{\beta} = 0{,}066$, igual al reportado en la Tabla 2 del paper. Sin embargo, el efecto verdadero del programa sobre estas alumnas es cero, ya que rindieron antes del sorteo de diciembre de 2000 y el programa no pudo afectarlas. El coeficiente estimado refleja solamente diferencias previas entre las escuelas que luego resultaron sorteadas y las que no. Aun así, con errores robustos el coeficiente resulta significativo incluso al 1 % ($p = 0{,}000$), lo que constituye un falso positivo. Los otros tres métodos no rechazan la hipótesis nula, con p-valores de 0,130 (agrupado), 0,157 (wild bootstrap) y 0,274 (aleatorización).

El único método que garantiza rechazar como mucho el 5 % de las veces, si el programa no tiene efecto sobre ninguna alumna y se repitiera el sorteo, es la inferencia por aleatorización. Su p-valor se calcula repitiendo el mismo sorteo que generó los datos, por lo que, bajo esa nula, el $\hat{\beta}$ observado es uno más entre todos los sorteos posibles y cae en el 5 % más extremo a lo sumo el 5 % de las veces. Los otros tres métodos dependen de aproximaciones, como la normalidad o tener muchas escuelas, que pueden acercarse al 5 % pero no lo garantizan.

Cuadro 4: Cuatro p-valores para $H_0 : \beta = 0$, mujeres de 2000

	Mujeres 2000
$\hat{\beta}$	0,066
Alumnas	2.001
Escuelas	35
Robusto	
p-valor	0,000
IC 95 %	[0,031; 0,101]
Agrupado por escuela	
p-valor	0,130
IC 95 %	[-0,020; 0,153]
Wild cluster bootstrap	
p-valor	0,157
IC 95 %	[-0,028; 0,160]
Aleatorización	
p-valor	0,274

Nota: Alumnas de último año de 2000, con todos los controles y sin efectos de par. Se reporta $\hat{\beta}$ y, para cada método, el p-valor de $H_0 : \beta = 0$ y el intervalo de confianza del 95 % cuando el método lo da.

b) Se usan todos los alumnos de 2000, con todos los controles y sin efectos de par, y se re-sortea `treated` 1.000 veces dentro de cada par, como en el sorteo original. En cada re-sorteo se estima la regresión y se guarda el p-valor de $H_0 : \beta = 0$ con errores robustos y con errores agrupados por escuela. Como en 2000 el programa no existía, el efecto verdadero es cero en todos los re-sorteos y cada $p < 0{,}05$ es un rechazo equivocado. El Cuadro 5 muestra los resultados.

Cuadro 5: Rechazos equivocados en 1.000 re-sorteos, 2000

	Rechazos al 5 % (%)
Sin efectos de par	
Robusto	61,7
Agrupado por escuela	8,5
Con efectos de par	
Agrupado por escuela	22,5
Agrupado por par	9,1

Nota: Todos los alumnos de 2000, con todos los controles. Se reporta el porcentaje de 1.000 re-sorteos de `treated` dentro de pares en que se rechaza $H_0 : \beta = 0$ al 5 %, para cada especificación y nivel de agrupado.

Con errores robustos se rechaza la nula en el 61,7 % de los re-sorteos, más de doce veces el 5 % que promete el test. Es el mismo resultado que las leyes inventadas de la clase, ya que el robusto trata a los 4.039 alumnos como independientes cuando el tratamiento se asignó por escuela. Al agrupar por escuela el rechazo baja a 8,5 %. Queda cerca del 5 % pero todavía por encima, lo que es esperable con solo 39 escuelas. Con 1.000 re-sorteos el error de simulación de una tasa del 5 % es de unos 0,7 puntos, por lo que la diferencia no es solo ruido.

c) Se repite (b) con efectos fijos de par, usando los mismos re-sorteos. Con efectos de par y errores agrupados por escuela se rechaza en el 22,5 % de los re-sorteos, mientras que agrupando por par se rechaza en el 9,1 %. El coeficiente es el mismo en las dos versiones, así que la diferencia viene solo del error estándar.

La razón es que, con efectos de par, $\hat{\beta}$ compara cada escuela tratada con la escuela de control de su mismo par. Dentro de un par, si una escuela salió tratada se sabe que la otra es control, por lo que las dos asignaciones salen de una sola moneda. Además, al sacar el promedio del par, el residuo de una escuela queda casi igual al de la otra con el signo cambiado. Entonces las contribuciones de las dos escuelas a $\hat{\beta}$ se mueven juntas y no son información independiente. Agrupar por escuela las trata como independientes, omite esa correlación positiva y subestima el error estándar. Agrupar por par la incluye, porque el par es el nivel en que se hizo cada sorteo. Sin efectos de par este problema no aparece, porque la comparación es entre todas las escuelas y los residuos de un mismo par no quedan atados entre sí. El 9,1 % sigue por encima del 5 % porque con 19 pares hay pocos grupos para que el error agrupado funcione bien.

d) Con todos los alumnos de 2001, todos los controles y efectos de par se obtiene $\hat{\beta} = 0{,}067$, igual al reportado en la Tabla 2 del paper. El Cuadro 6 muestra los errores estándar agrupados por escuela y por par.

Cuadro 6: Efecto en 2001 con efectos de par

	2001, con efectos de par
$\hat{\beta}$	0,067
Agrupado por escuela (39 grupos)	
Error estándar	0,0256
p-valor	0,012
Agrupado por par (19 grupos)	
Error estándar	0,0356
p-valor	0,074
Error estándar BRL (paper)	0,036

Nota: Todos los alumnos de 2001, con todos los controles y efectos fijos de par. Se reporta $\hat{\beta}$ y el error estándar y el p-valor agrupando por escuela y por par, junto con el error estándar BRL del paper.

Agrupando por escuela el error estándar es 0,026 y el efecto es significativo al 5 % ($p = 0{,}012$). Agrupando por par el error estándar sube a 0,036, prácticamente igual al BRL del paper, y el efecto deja de ser significativo al 5 % ($p = 0{,}074$). Con lo encontrado en (c) usaría el agrupado por par, ya que con efectos de par el agrupado por escuela rechaza una nula verdadera en el 22,5 % de los re-sorteos. Su $p = 0{,}012$ no es creíble. Lo anterior también cambia la lectura del 0,105 de las mujeres. En 2000, cuando el programa no podía tener efecto, las mujeres de las escuelas que después salieron sorteadas ya tenían una tasa de Bagrut 6,6 puntos mayor. Ese 0,066 no es significativo, pero equivale a casi dos tercios del 0,105. Por lo tanto, una parte del efecto estimado en 2001 puede reflejar diferencias previas entre las escuelas y no el programa. Sumado a que el p-valor por aleatorización de 2001 es 0,085, la evidencia de un efecto en las mujeres es más débil de lo que sugiere el error agrupado por escuela. Por esta misma preocupación, los autores estiman en el paper modelos con efectos fijos de escuela que combinan 2000 y 2001.